

Documento 1 - Técnicas de reducción de dimensión: PC, t-SNE y UMAP

Raúl Llamosas Alvarado Eumir Rendon Uresti Gabriela Peña Franco Daniela Ibarra Gatica
Randy Jesús García Mejía Daniela Vázquez Sánchez

Table of contents

Introducción	1
Estadística descriptiva	1
Técnicas de reducción de dimensión	4
PC	4
t-SNE	7
UMAP	11
Conclusión	16

Introducción

Nuestro proyecto consiste en usar técnicas de reducción de dimensión en el siguiente dataset: `habits.csv`, el cual es un dataset con información acerca de los hábitos de estudiantes, como lo pueden ser su consumo en horas de redes sociales, sus hábitos alimenticios, resultados de examen, etc. La idea es intentar agrupar usando solamente sus hábitos y ver si estos tienen alguna incidencia sobre su calificación de examen. Nuestra intuición nos dice que aquellos estudiantes con buenos hábitos deberían tener buenas notas.

Todo nuestro código se encuentra en el [siguiente repositorio de GitHub](#).

Estadística descriptiva

Vamos a cargar nuestro dataset. A continuación mostraremos solo una parte de este para no saturar la página por lo que no incluye todas las columnas.

Horas de Estudio	Redes Sociales	Netflix	Salud Mental	Resultado Examen
0	1.2	1.1	8	56.2
6.9	2.8	2.3	8	100
1.4	3.1	1.3	1	34.3
1	3.9	1	1	26.8
5	4.4	0.5	1	66.4

Tenemos 4 variables categóricas:


- `gender`
- `diet_quality`
- `parental_education_level`
- `internet_quality`

Dos booleanas:

- `extracurricular_participation`
- `part_time_job`


El resto de las variables son numéricas. La distribución por género del dataset es la siguiente:

Distribución por género del dataset.



Y la matriz de correlación es la siguiente:


Matriz de Correlación de Hábitos Estudiantiles




Notamos lo siguiente:

- La correlación más alta es la de **exam_score** con **study_hours_per_day** con 0.81.
- La segunda correlación más alta es la de **exam_score** con **mental_health_rating** con 0.32.
- Hay correlaciones negativas entre **exam_score** con **netflix_hours** y **social_media_hours** respectivamente. Ambas del 0.17

De esto podemos intuir que estudiar más horas al día y tener buena salud mental tiene un efecto positivo sobre las notas del examen. También que tener pobres hábitos respecto al uso de desmedido de redes sociales tiene un efecto negativo sobre dichas notas. A continuación, graficaremos la relación entre `study_hours_per_day` con `exam_score`



Ahora, graficaremos la relación entre las variables categóricas con el resultado del examen:



Podemos notar, que parece no tener mucha incidencia en la variable `exam_score`. Lo cual coincide con lo mencionado arriba respecto a las correlaciones.

Técnicas de reducción de dimensión

PC

Comenzaremos con nuestra reducción PCA

Vamos a estandarizar nuestras variables y lidiar con las variables categóricas mencionadas en el paso anterior por medio de la siguiente codificación

```
library(dplyr)

df_encoded <- df %>%
  mutate(
    part_time_job = ifelse(part_time_job == "No", 1, 0),
    extracurricular_participation = ifelse(extracurricular_participation == "Yes", 1, 0),

    gender = ifelse(gender == "Male", 0, 1),

    internet_quality = case_when(
      internet_quality == "Poor" ~ 0,
      internet_quality == "Average" ~ 1,
      internet_quality == "Good" ~ 2
    ),

    diet_quality = case_when(
      diet_quality == "Poor" ~ 0,
      diet_quality == "Fair" ~ 1,
      diet_quality == "Good" ~ 2
    ),

    parental_education_level = case_when(
      parental_education_level == "None" ~ 0,
      parental_education_level == "High School" ~ 1,
      parental_education_level == "Bachelor" ~ 2,
      parental_education_level == "Master" ~ 3
    )
  )
```

De esta manera se le asigna a las variables categóricas un valor numérico, de lo contrario los modelos no funcionarían. Ahora vamos a correr la receta del PCA, removiendo la variable `exam_score` de la siguiente manera:


```
df_pca <- df_encoded %>% select(-exam_score)

receta_pca <- recipe(~ ., data = df_pca) %>%
  step_normalize(all_predictors())


datos_preparados <- prep(receta_pca) %>%
  bake(new_data = NULL)

datos_finales <- datos_preparados %>%
  bind_cols(exam_score = df$exam_score)
```


Con lo cual obtenemos la siguiente gráfica que explica la varianza acumulada.




Notamos que necesitamos muchas componentes para explicar varianza.





Notamos que los que se acercan al rojo están en la esquina superior izquierda, los más verdes parecen concentrarse en la esquina inferior derecha Y en medio tienes a calificaciones entre 60 y 80. Vamos a colorear de otra forma para que quede ilustrado de una mejor manera.



Si bien, ayuda a visualizar que los estudiantes se agrupan por color (calificación baja arriba, alta abajo, etc) no se agrupan de una manera suficientemente tajante a comparación de los ejemplos que vimos en clase. Veamos la correlación entre las componentes y el resultado de examen.



Y ahora las cargas de las componentes.



Estos primeros resultados parecen indicar que si excluimos **exam_score** de nuestro dataset, tenemos dificultades con notar agrupaciones claras respecto a las calificaciones.

t-SNE

Ahora pasaremos al metodo t-SNE

Al ejecutar el siguiente bloque de código ya habríamos de haber codificado el dataset como lo hicimos en el paso anterior.


```
set.seed(123)

start.time <- proc.time()


df_tsne <- df_encoded %>%
  scale() %>%
  tsne()

proc.time()-start.time
```


Sin algun distintivo veremos que no existen grupos definidos cuando no declaramos hiperparametros



Parece existir una aglomeración en la esquina superior derecha.




Pero al intentar colorear por calificación, parece que no se agrupan de esta manera.




En este caso tsne no muestra una separacion tan evidente como en el caso de pca, aunque si se puede notar un degradado, debemos recordar que aun no establecemos ningun hiperparametro

Distribución de tSNE por Grupo de Calificación




Veremos que existen ligeros traslapes entre el como tsne hace una diferencia en los grupos, aunque se puede notar que es significativa, puede indicar que puede ser mejor que pca




Esta gráfica muestra de forma un poco más clara nuestra separación entre grupos sin alterar demasiado las dimensiones del gráfico. Debemos recordar que este algoritmo uso la primera version de tsne ahora pasaremos a demostrar el poderio de la libreria de rtsne

WDBC: Rtsne




En este caso, podemos notar una agrupación en la izquierda.




Pero parece no estar agrupada por calificación. Veremos que gracias a esta libreria la dispersion entre nuestros grupos y los datos en general es mejor, demostrando un mejor uso de la reduccion de dimension para explicar la varianza de nuestros datos


Distribución de Dimensiones Rtsne por Grupo de Calificación





En este caso nuestro algoritmo nos da un traslape entre nuestros grupos ligeramente menos eficientes para los grupos intermedios, aunque para los extremos sigue siendo eficiente para los grupos de los extremos



Esta grafica es un poco mas visible






Conclusión, a pesar de que algunos gráficos muestran una separación prometedora, esta parece no responder a alguna variable como `exam_score`, notamos este patrón con otras columnas también, como lo son `mental_health_rating`. Podrán existir muchas explicaciones respecto a esto, una de ellas podría ser que tener buenos hábitos no necesariamente se refleja en las calificaciones de un determinado estudiante (un estudiante con buenas notas podría tener alguna adicción a las redes sociales, o bien un estudiante con malas notas podría tener buenos hábitos). Claro, esta conclusión depende estrictamente del dataset que estamos trabajando.

UMAP


Vamos a hacerle la misma modificación al dataset con respecto a las variables categóricas. Después de esta modificación tenemos:

UMAP – Estudiantes por Hábitos



UMAP sí logra generar grupos, esto tiene sentido dado que UMAP genera grupos basado en vecinos cercanos. Pero, habremos de tener cuidado con saltar a conclusiones, dado que UMAP puede generar grupos artificiales, aunque no existiese una estructura como tal. Por ejemplo, a continuación coloreamos por grupos basados en `exam_score`


UMAP – Estudiantes por Grupo de Calificación




Y aquí por `attendance_percentage`:

UMAP – Estudiantes por Cuantil de Asistencia


Cada grupo contiene ~33% de los estudiantes



UMAP – Estudiantes por Hábitos



UMAP – Estudiantes por Grupo de Cal




Grupo de Calificación ● Alto ● Medio ● Bajo

Comparemos los distintos parámetros con los que corremos UMAP:

UMAP – Comparación de Parámetros

Efecto de $n_neighbors$ (5–100) y min_dist (0.1–1.1) en la visualización




Grupo de Calificación ● Alto ● Medio ● Bajo

UMAP – Comparación de Parámetros

Efecto de $n_neighbors$ y min_dist en la visualización



UMAP – Modelo Final ($min_dist = 0.1$, $n_neighbors = 15$)



Conclusión

Usando los tres métodos , parece haber una fuerte indicación de que no podemos dividir a los estudiantes en categorías o grupos usando la información que tenemos. Lo que encontramos en el paso de análisis de datos es que hay poca correlación entre las variables, la más fuerte que hay con exam_score es la de horas de estudio. Pero las demás no tienen mucha relevancia. Si hay grupos, no son claros de observar. Esto, puede que tenga sentido intuitivo, pues un estudiante que saca buenas notas puede ser muy variado en su actuar, podría tener malos o buenos hábitos ya sea alimenticios o de consumo de redes sociales.