



Documento 2 - Técnicas de agrupamiento o clustering: Clusters por métodos aglomerativos y por método de k-means

Raúl Llamosas Alvarado Eumir Rendon Uresti Gabriela Peña Franco Daniela Ibarra Gatica
Randy Jesús García Mejía Daniela Vázquez Sánchez

Table of contents

Introducción	1
Métodos aglomerativos	1
Linkage	1
Hopkins	3
Método Silueta	4
Dendogramas circulares y filogenéticos	5
Otros Métodos (Gap, Codo, Silueta)	6
k-Means	8
Conclusión	11

Introducción

Todo nuestro código se encuentra en el [siguiente repositorio de GitHub](#). Esta es una continuación del proyecto, ahora relacionado con métodos de aglomeración (clustering) sobre el mismo conjunto de datos trabajado en la primera parte.

Métodos aglomerativos


De igual manera que en paso anterior, vamos a trabajar nuestras variables categóricas con codificación:

Linkage


Procedemos a calcular la distancia cophenetic:

A continuación, el “linkage” promedio y completo:

Average Linkage




Complete Linkage




Ahora, calculamos la ward:

Ward Linkage




Ward2 Linkage



Notamos que si cortamos Ward en 100 tenemos tres agrupaciones, de igual manera si cortas Ward 2 en 30 tenemos tres agrupaciones.

Ahora, para single:



Cortamos en 27, y tenemos tres agrupaciones.

Hopkins

Ahora, usaremos la estadística de Hopkins para saber si hay alguna tendencia para agruparse en clusteras:

```
library(hopkins)

set.seed(123)
Hopkins_tend <- factoextra::get_clust_tendency(
  df_encoded, n = nrow(df_encoded) - 1,
  gradient = list(low = "steelblue", high = "white")
)
cat("Hopkins statistic:", round(Hopkins_tend$hopkins_stat, 3), "\n")
```

Hopkins statistic: 0.989

```
cat("Interpretación:",
  ifelse(Hopkins_tend$hopkins_stat > 0.7, "Los datos presentan una tendencia a agruparse en clusteras (H > 0.7)",
  ifelse(Hopkins_tend$hopkins_stat > 0.5, "Existe alguna tendencia al agrupamiento en los datos (H > 0.5)",
  "Los datos presentan una distribución espacial uniforme: La agrupación sería cuestionable")), "\n")
```

Interpretación: Los datos presentan una tendencia a agruparse en clusteras (H > 0.7)

```
set.seed(123)
hopkins::hopkins(df_encoded)
```

[1] 0.9813877


Resultado de 0.989, por lo que sí se agrupan en clusteras. No obstante, es anormalmente alto. Necesitaremos más pruebas.

Método Silueta

Vamos a usar ahora la métrica conocida como coeficiente de silueta. Con esta métrica mediremos la similitud de una observación con su propio cluster en comparación con otros clusteres.



Proceso tuning de cluster: Silhouetti

Evaluación de k = 1 to 10 con 5 folds




A juzgar por el método silueta,habríamos de elegir tres clusters.

Cortamos en tres clusters por medio de un dendrograma:




Dendogramas circulares y filogenéticos




No obtenemos agrupaciones satisfactorias. Lo cual coincide con lo dicho con el documento 1 de técnicas de reducción de dimensión. Pasaremos ahora a visualización por silueta:

Métodos para Determinar el Número Óptimo de Clusters




Podemos notar, que no hay un patrón consistente para afirmar un número adecuado de clusters. Esto va acorde a las observaciones del primer documento. Nuestro conjunto de datos parece no acomodarse en clusters de forma natural.

```
stats::as.dist(dmat)
stats::hclust (*, "ward.D2")
```



k-Means

Para k-means vamos a determinar por medio del método del codo y de la silueta el número adecuado de clusters que necesitamos:




Podemos apreciar entonces:

- Para la primera gráfica, el número adecuado es 4
- Para la segunda parece ser 5
- Para la tercera es 3


No es consistente. Veamos más pruebas.

Warning: The `size` argument of `element\_rect()` is deprecated as of ggplot2 3.4.0.
i Please use the `linewidth` argument instead.



Usando k=3 no obtenemos una clara separación.


Métodos para Determinar el Número Óptimo de Clusters



En este resumen podemos notar que hay una recomendación inconsistente de número de clusters. Unos recomiendan 3, otros 2 y hay uno que no logró recomendar nada con base en la varianza explicada (eso sucede por lo visto en el documento 1 donde vemos que se necesitan demasiadas componentes para explicar un buen porcentaje de varianza).

Visualización de Clusters K-Means

A) Clusters con K-Means (k=3)




B) Clusters con Elipse Normal (k=3)



De igual manera, notamos que no se agrupan. Los clusters no están separados. Hay una intersección increíble entre los tres.

Distribución de Variables por Cluster

K-Means con k = 3 clusters | Incluyendo Resultado Examen




Podemos notar que entre clusters no hay mucha diferencia. Ni los resultados de examen ni los hábitos parecen agruparse de alguna manera.

Análisis de Clustering con PCA

PCA – Cluster Distribution

K-Means con $k = 2$



Conclusión

Parecido a lo que concluimos en el documento 1, este conjunto de datos no se agrupa de manera natural. Esto quiere decir que no pudimos agrupar a los estudiantes por sus hábitos y que estos tampoco tuvieron incidencia alguna en sus calificaciones. Al notar esto, intentamos agregar `exam_score` como parte de los datos, pero esto tampoco ayudó mucho. Además de que lo único que ocasionaría sería tener data leakage. Si existiese una agrupación natural, los distintos métodos (codo, silueta, etc) tendrían un valor k similar. Pero no es así. Esto concuerda con lo que vimos en clase, no todos los conjuntos de datos se agruparan de forma natural, si algo indica lo que encontramos en las pruebas fue que los estudiantes son diversos.