

Documento 1 - Técnicas de reducción de dimensión: PC, t-SNE y UMAP

Raúl Llamosas Alvarado Eumir Rendon Uresti Gabriela Peña Franco Daniela Ibarra Gatica
Randy Jesús García Mejía Daniela Vázquez Sánchez

Table of contents

Introducción	1
Estadística descriptiva	1

Introducción

Nuestro proyecto consiste en usar técnicas de reducción de dimensión en el siguiente dataset: `habits.csv`, el cual es un dataset con información acerca de los hábitos de estudiantes, como lo pueden ser su consumo en horas de redes sociales, sus hábitos alimenticios, resultados de examen, etc. La idea es intentar agrupar usando solamente sus hábitos y ver si estos tienen alguna incidencia sobre su calificación de examen. Nuestra intuición nos dice que aquellos estudiantes con buenos hábitos deberían tener buenas notas.

Todo nuestro código se encuentra en el [siguiente repositorio de GitHub](#). También tenemos en la [siguiente liga](#) gráficos en 3D.

Estadística descriptiva

Vamos a cargar nuestro dataset. A continuación mostraremos solo una parte de este para no saturar la página por lo que no incluye todas las columnas.

Horas de Estudio	Redes Sociales	Netflix	Salud Mental	Resultado Examen
0	1.2	1.1	8	56.2
6.9	2.8	2.3	8	100
1.4	3.1	1.3	1	34.3
1	3.9	1	1	26.8
5	4.4	0.5	1	66.4

Tenemos 4 variables categóricas:

- `gender`
- `diet_quality`
- `parental_education_level`
- `internet_quality`


Dos booleanas:

- `extracurricular_participation`
- `part_time_job`

El resto de las variables son numéricas. La distribución por género del dataset es la siguiente:


```
(np.float64(-1.1219432318309703), np.float64(1.1216036977116117), np.float64(-1.1049875859245983), np.float64(1.121007759738873))
```

Distribución por género del dataset.



Y la matriz de correlación es la siguiente:


Matriz de Correlación de Hábitos Estudiantiles




Notamos lo siguiente:

- La correlación más alta es la de **exam_score** con **study_hours_per_day** con 0.81.
- La segunda correlación más alta es la de **exam_score** con **mental_health_rating** con 0.32.
- Hay correlaciones negativas entre **exam_score** con **netflix_hours** y **social_media_hours** respectivamente. Ambas del 0.17

De esto podemos intuir que estudiar más horas al día y tener buena salud mental tiene un efecto positivo sobre las notas del examen. También que tener pobres hábitos respecto al uso de desmedido de redes sociales tiene un efecto negativo sobre dichas notas. A continuación, graficaremos la relación entre `study_hours_per_day` con `exam_score`



Ahora, graficaremos la relación entre las variables categóricas con el resultado del examen:



Podemos notar, que parece no tener mucha incidencia en la variable `exam_score`. Lo cual coincide con lo mencionado arriba respecto a las correlaciones.